

基于多模态大模型与 YOLO 目标检测的盲人避障导航系统

开题报告

一、选题背景与意义

1.1 研究背景

根据世界卫生组织发布的统计数据来进行分析，全球视觉障碍人口的规模已经超过了 2.85 亿，其中大约有 3900 万人处于完全失明的状态当中。而在我国，视障人群的数量也高达了 1700 多万人。视障人士在进行日常出行活动的过程中会面临巨大的挑战，尽管传统的导盲犬以及盲杖能起到一定程度的辅助作用，但在实际应用层面却有着成本高昂、适用范围有限以及功能单一这些显著的局限。因此，去致力于研发一套兼具智能化、低成本以及高效能特性的盲人导航避障系统，是具备了非常重要的现实意义的。

纵观近几年的发展历程，人工智能技术领域已经获得了一系列具有突破性的发展成果。在这当中，像 ChatGPT 这样的大语言模型也就是 LLM，已经充分地展现出了极为强大的语义理解能力以及逻辑推理的能力；与此同时，以 YOLO 也就是 You Only Look Once 系列为代表的目标检测算法，在对实时物体进行识别的这个领域里，也成功地实现了极高的准确率以及处理速度。随着多模态大模型即 MLLM 的迅速兴起，这不但让视觉信息与语言信息之间的深度融合得以实现，还为智能导航系统的构建工作提供了坚实的技术支撑。

视觉语言模型也就是 VLM，主要是依靠把视觉特征进行映射，使其进入到语言模型可以理解的那个语义空间内部，进而让跨模态信息的对齐处理以及深度的理解工作得以实现。像 VisionGPT 这样的研究工作显示出，如果把大语言模型以及 YOLO-World 这些先进的目标检测模型进行深度的结合，就可以去实现零样本异常检测，以及具备实时特性的视觉导航辅助功能。除此之外，那些基于 LLM 来构建出的具身智能体即 Embodied Agent，在目标导航任务这个方面当中，也展现出了极为出色的表现，在这当中，LGX 也就是 Language-Guided eXploration 算法，更是在零样本物体导航领域里面，达到了最先进的水平。

1.2 研究意义

（1）理论意义

本次的研究工作主要致力于去把多模态大模型以及目标检测技术来进行深度的融合，想借助这个方式来对视觉-语言对齐也就是 VLA 技术，在辅助导航场景当中的具体应用模式进行探索。在整个研究开展的过程当中，核心的任务就在于要去解决下面这些关键的理论问题：也就是怎样才能实现 YOLO 检测结果和大模型语义空间这两者之间的高效关联；还有怎样去构建出一个专门面向盲人导航场景的领域知识库；以及要如何对实时推理的性能来进行优化，这样一来就能充分满足移动场景下的实际需求。这一系列的研究工作，将会能够极大程度上丰富多模态大模型在特定垂直领域应用层面的理论体系。

（2）实践意义

这个系统主要的开发目标，在于去构建一种同时具备了较低成本优势以及较高效率特性的智能导航解决方案，以此来服务于视障人士。依靠对周围环境当中存在的障碍物开展实时的检测工作，并且结合自然语言这种形式来进行语音层面的提醒，这样一来，就能够使得视障人士在出行过程当中的安全性还有独立性得到显著的提升。除此之外，这个系统是可以被集成在智能手机或者是可穿戴设备内部的，这样也就拥有了良好的便携性还有实用性，并且有希望在社会福利以及无障碍环境的建设工作方面，去发挥出积极的推动作用。

（3）社会意义

视障人士是社会结构当中迫切需要去给予特别关怀的一个群体，而去开展智能辅助类相关的技术开发工作，可以说正是“科技向善”这个理念的重要体现。围绕着本系统来开展的研发以及推广工作，将会对于去构建出一个更加包容以及无障碍的社会环境有帮助，从而能够深刻地展现出人工智能技术在服务人类这个方面所具备的核心价值。

二、国内外研究现状

随着人工智能技术的快速发展，有关于如何将大语言模型即 LLM，和视觉感知技术去进行有效的融合，从而能够让机器人拥有对复杂指令进行深度理解，并且去执行自主决策的能力，这一点已经变成了当下学术界当中非常关注的一个研究热点。

对于目标搜索还有导航这个领域来说，Dorbal 等人^[1]提出了一种算法叫做 LGX，这个算法凭借大语言模型本身拥有的常识推理能力，来指导机器人去进行零样本也就是 Zero-Shot 模式下的目标导航任务。这项研究主要是依靠 LLM 去制定

序列化的导航决策，并且还结合了预训练的视觉语言接地模型，这样一来就得以实现对像“猫咪形状的杯子”这种具有唯一性描述的目标的精准探测，让在复杂未知环境当中的任务成功率得到了很大程度的提高。为了能够去保障导航过程当中的安全性，Wang 等人^[2]开发了一套框架叫 VisionGPT，它选用了 YOLO-World 实时目标检测模型还有定制化的提示词，用来帮助机器人在视觉导航的过程当中去识别障碍物以及各种异常情况，同时生成简明的音频描述以此来辅助它做出避障的决策。

在无人机也就是 UAV 这个应用领域当中，研究者们也一样进行了大量有关于语义理解方面的研究工作。De Curtò 等人^[3]针对无人机在大语言模型这项技术的支持下面所拥有的语义场景理解能力，开展了深入的探讨。紧接着，为了能够去解决自动驾驶任务当中对于复杂指令进行解析的这个问题，Ryu 等人^[4]提出了一种名字叫“Words to Wheels”的解决方案。这个方案凭借基础模型把人类的语言指令转化成为了“认知路线描述”，并且依靠地形分割模型 GANav 还有模型预测路径积分即 MPPI 控制器，得以成功实现了基于视觉感知来开展的自主导航功能。同时，Zhu 等人^[5]通过把多种基础模型进行整合从而搭建出了一套视觉语言决策系统，让服务机器人在导航过程当中的逻辑判断还有任务规划的能力获得了显著的增强。

为了能够去满足无人机在各种各样不同的环境当中去开展端到端引导的任务需求，Saxena 等人^[6]提出了一套被叫作 UAV-VLN 的框架。这个框架成功地得以实现了对人类自然语言指令还有视觉观测数据进行深度的融合处理，这样一来就让无人机拥有了对空间关系进行深入理解，并且去规划出切实可行的飞行轨迹的能力，从而展现出了非常强的泛化性能。针对于人机共存的社交环境场景方面，Song 等人^[7]提出了一种名字叫做 VLM-Social-Nav 的方法，这个方法主要是凭借 VLM 评分模块来对路径去开展评估的工作，从而让机器人在去执行导航的过程当中，能够切实地去遵循人类的社交礼仪以及期望，这样一来也就显著地减少了系统对于大规模训练数据集的依赖程度。

前面所提到的这些导航以及决策系统能够去进行高效的运行，主要是依靠底层感知模型在其中所提供的坚实支撑作用。在目标检测这个领域当中，Redmon 等人^[8]提出来的 YOLO 模型成功地把实时目标检测的基础给奠定了，它主要是凭借把检测任务去当作回归问题来处理，这样一来就让处理的速度获得了很大程度的提高。在这之后，Wang 等人^[9]依靠对可编程梯度信息即 PGI 的引入工作，把 YOLOv9 推出来了，这个模型它不光是得以实现了对深层网络当中信息瓶颈问题的有效解决，同时也让在复杂场景下面的检测精度得到了显著的提升。

在多模态理解以及训练策略这个方面当中，Liu 等人^[10]提出来的 LLaVA 模型主要是依靠视觉指令微调也就是 Visual Instruction Tuning 这项技术，成功地得以实现了视觉编码器以及大语言模型它们两者之间的有效连接，这样一来就让这个模型拥有了去开展通用视觉辅助对话的能力。被当作是目前性能最为强劲的基础模型其中的一个，由 OpenAI 发布的 GPT-4 技术报告^[11]，针对它在去对多模态输入进行处理，还有去开展复杂推理任务这些方面所展现出来的卓越表现，进行了十分详细的阐述。而上面所说到的这些进步，在很大程度上是得益于 Radford 等人^[12]提出来的 CLIP 模型，这个模型它主要是凭借大规模自然语言监督这种机制，来对可迁移的视觉表示去开展学习的工作，这样一来也就为后续视觉语言模型所去进行的零样本学习以及跨模态对齐的工作，把核心的技术路径给奠定下来了。

结合上述内容来看，目前国内还有国外的相关研究工作，正在经历着从比较单一的视觉感知这种模式，朝着多模态融合，以及拥有常识推理能力的具身智能这个方向，去开展快速的演进工作。那些把基础模型当作基础来进行构建的导航算法，在零样本泛化、社交合规性还有实时异常检测这些个关键的方面当中，都已经展现出了非常巨大的应用潜力。

三、研究内容与技术路线

3.1 主要研究内容

本课题将会去紧紧围绕着盲人避障导航系统所去面临到的那些核心功能方面的需求来进行展开，并且还会在以下这四个非常关键的维度上面，去开展深入同时也是系统的研究工作：

（1）大模型选型与微调

对于像 ChatGLM、Qwen 以及 LLaMA 这一类目前主流的开源大语言模型，去开展十分深入的调研工作，并且针对它们在核心性能方面所具备的特性，去进行系统性的分析。

针对盲人导航这个特定的应用场景，去开展有关于领域知识库的构建工作，并且与此同时，去建立起一套能够和它相互配套的指令数据集。

运用比如像 LoRA 也就是 Low-Rank Adaptation 这一类效率非常高的微调技术，去开展针对于特定领域去进行适配的相关工作。

针对模型的推理速度去开展相关的深度优化工作，这样一来就能够去保障它在实际运行的过程当中，能够切实地去满足实时性应用方面的具体要求。

（2）多模态大模型对齐技术

- 研究 VLM (Vision-Language Model) 和 VLA (Vision-Language-Action) 相关技术
- 设计 YOLO 检测结果到语言空间的映射策略
- 实现目标物体的空间位置、类别、距离等信息的语义关联
- 构建统一的多模态表示框架，支持视觉-语言推理

（3）原型系统开发

- 设计并实现具有图形界面的交互式原型系统
- 集成摄像头采集、YOLO 目标检测、大模型推理、语音合成等功能模块
- 实现障碍物场景下的实时语音提醒和路径建议
- 优化用户交互体验，支持语音输入等无障碍交互方式


（4）系统测试与评估

- 设计功能测试用例，验证各模块的正确性
- 进行性能测试，评估系统的实时性和资源消耗
- 开展用户测试，收集视障人士的使用反馈
- 对比分析与现有辅助导航方案的优劣

3.2 技术路线

本系统采用模块化分层架构设计，技术路线如下：

基于多模态大模型与YOLO的盲人避障导航系统技术路线图



3.3 关键技术

(1) 高效目标检测

- 采用 YOLOv8 或 YOLO-World 作为基础检测模型
- 针对盲人导航这一特定的应用场景，去对模型开展了轻量化的处理工作，并且实施了运行加速层面的优化工作。
- 支持多类别障碍物（行人、车辆、台阶、电线杆等）的实时检测

(2) 视觉语言对齐

- 参考 AlignVLM、VIRAL 等对齐策略
- 设计检测结果到自然语言的结构化映射
- 融合空间位置信息和语义类别信息

（3）大模型推理优化

- 采用模型量化（INT8/INT4）降低计算需求
- 使用 Ollama 等本地部署方案
- 探索流式推理以降低延迟

（4）语音交互

- 集成 TTS（Text-to-Speech）实现语音输出
- 支持 ASR（Automatic Speech Recognition）语音输入
- 设计简洁明了的语音提示模板

四、研究计划与进度安排

阶段	时间	主要工作内容
第一阶段	第 1-2 周	文献调研，完成开题报告，熟悉相关技术
第二阶段	第 3-6 周	熟悉环境及开发工具。
第三阶段	第 7-12 周	掌握相关理论与方法；实现相应功能。
第四阶段	第 13-16 周	撰写论文、制作答辩 PPT 等，准备答辩

五、预期成果

1. **原型系统一套**：具有图形界面的盲人避障导航系统，支持实时障碍物检测和语音提醒功能
2. **技术文档**：完整的系统设计文档、API 文档和用户手册
3. **测试报告**：功能测试和性能测试报告
4. **毕业论文**：不少于 1.5 万字的毕业设计报告（含 4000 字软件使用说明）
5. **源代码**：完整的 Python 源程序

六、可行性分析

6.1 技术可行性

- **成熟的开源生态**：YOLO、Transformers、PyTorch 等开源框架提供了完善的技术支持
- **丰富的预训练模型**：ChatGLM、Qwen-VL 等开源大模型可直接使用或微调
- **成功的前期研究**：VisionGPT、LGX 等工作验证了技术路线的可行性

6.2 资源可行性

- **硬件资源**：普通计算机配合 GPU 可满足开发和测试需求

- **数据资源：**可利用公开数据集（COCO、ImageNet 等）进行模型训练
- **时间资源：**16 周的研究周期可以完成预期目标

6.3 经济可行性

- 采用开源软件和模型，无软件授权费用
- 系统可部署在普通智能手机或便携设备上，成本可控

七、参考文献

- [1] Dorbala V S, Mullen J F, Manocha D. Can an embodied agent find your "cat-shaped mug"? Llm-based zero-shot object navigation[J]. IEEE Robotics and Automation Letters, 2023, 9(5): 4083-4090.
- [2] Wang H, Qin J, Bastola A, et al. Visiongpt: Llm-assisted real-time anomaly detection for safe visual navigation[J]. arXiv preprint arXiv:2403.12415, 2024.
- [3] De Curtò J, De Zarza I, Calafate C T. Semantic scene understanding with large language models on unmanned aerial vehicles[J]. Drones, 2023, 7(2): 114.
- [4] Ryu C, Seong H, Lee D, et al. Words to wheels: Vision-based autonomous driving understanding human language instructions using foundation models[C]//2025 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2025: 2200-2207.
- [5] Zhu P, El Hafi L, Taniguchi T. Visual-language decision system through integration of foundation models for service robot navigation[C]//2024 IEEE/SICE International Symposium on System Integration (SII). IEEE, 2024: 1288-1295.
- [6] Saxena P, Raghuvanshi N, Goveas N. UAV-VLN: End-to-End Vision Language guided Navigation for UAVs[J]. arXiv preprint arXiv:2504.21432, 2025.
- [7] Song D, Liang J, Payandeh A, et al. Vlm-social-nav: Socially aware robot navigation through scoring using vision-language models[J]. IEEE Robotics and Automation Letters, 2024.
- [8] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [9] Wang C Y, Yeh I H, Liao H Y M. YOLOv9: Learning what you want to learn using programmable gradient information[J]. arXiv preprint arXiv:2402.13616, 2024.
- [10] Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2024, 36.
- [11] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.
- [12] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PMLR, 2021: 8748-8763.